

2026/03/10 書報討論演講報告：

智慧魚缸及口罩檢驗管理系統

演講者：國立臺中科技大學資訊與流通學院院長 陳永隆教授

1. 演講背景與核心議題導引

在實驗室開發模型的過程中，往往容易陷入「刷榜」的數字遊戲，追求極限的技術指標，卻忽略了系統在實務環境落地的複雜度。本次有幸聆聽國立臺中科技大學資訊與流通學院院長陳永隆教授的講座，主題環繞在智慧系統的設計與具體應用。教授透過其團隊的研究成果，展示了如何跨越純演算法的範疇，將硬體整合、通訊協定與深度學習優化結合，解決產業界與生活中的痛點。

在當前資工研究環境中，將「智慧系統設計」與「模型優化」結合已成為跨領域挑戰的核心。本次演講涵蓋了三大關鍵主題：

- **智慧魚缸 IoT 系統：**以邊緣計算與自動化通訊協議實現環境穩定性。
- **基於 CNN 的口罩瑕疵檢測：**探討影像預處理(IP)對工業級品質控制(QC)的決定性影響。
- **遙測影像中的 YOLOv8 改良：**分析如何透過架構微調(Transformer 與 Attention)解決高解析度影像偵測難題。

本篇心得將從物聯網的系統架構實踐出發，逐步深入演算法的底層優化邏輯，並反思其對於筆者未來研究的啟發。

2. 智慧魚缸：從 IoT 邊緣計算到家庭自動化整合

智慧魚缸系統不僅是感測器的堆疊，更是物聯網中「邊緣計算」與「使用者體驗」結合的縮影。其戰略意義在於透過技術手段，解決了水族維護中因人為疏忽導致的生態不穩定性。

根據演講中的系統概念圖，該系統展現了高度的模組化特質。技術棧包括 Python、OpenCV、ESP32 與 ESPHome。最值得關注的是其資料流架構：由 OpenCV 捕捉即時影像流後，透過 **MQTT 通訊協定** 作為橋樑，將資料傳輸至 Home Assistant 平台。這種設計允許高層級的邏輯編排與低層級的硬體執行(ESP32/繼電器)解耦，是典型的「系統中的系統」(System of Systems)開發模式。

以下整理硬體感測器與自動化執行動作的邏輯關聯，並參考電腦控制介面之實

測值：

硬體感測器	監測指標與實測範例	對應執行動作
溫度感測器	水溫（實測 26.9°C）低於預設臨界值	觸發繼電器開啟加熱棒
混濁度感測器	水質指標（實測 10.46）低於清澈標準	發送換水提醒或啟動排水馬達
光度感測器	環境照度（實測 6.33）不足時	自動開啟 LED 補光燈
影像監控	透過 OpenCV 辨識不同魚種行為	調整餵食頻率或自動定時餵食

這套系統的核心競爭力在於 MQTT 通訊協定的成功導入，它解決了 Python/OpenCV（高層級運算）與 ESP32/Relays（低層級控制）之間的通訊門檻。對研究生而言，這代表系統開發不應盲目追求從零打造（Reinventing the wheel），而是應利用 Home Assistant 這種成熟的模組化架構來提升開發效率，將精力集中在邊緣端的邏輯即時性優化。

隨著系統層面的實踐完備，影像特徵的精準處理成為下一個戰場，這在工業瑕疵檢測中尤為關鍵。

3. 卷積神經網路（CNN）於產品瑕疵檢測的實務應用

在工業品質控制中，影像分類任務的穩定性直接影響產線效能。陳教授分享的「口罩檢驗管理系統」展示了如何針對特定缺陷類型進行模型優化。

根據實驗數據，影像預處理（Image Preprocessing, IP）的作用不容小覷。在口罩檢測中，IP 步驟（如長寬比檢驗與剪裁）直接對應到特定的缺陷類別。例如若長寬比不正確，系統會直接判定為「裁切瑕疵」；其餘則交由模型判別是否為「掛繩斷裂」、「沒有掛繩」或「邊條過長」。

- **IP-ResNet152V2 的實務意義：**引用數據，加入 IP 後，ResNet152V2 在 60 回合訓練後的驗證集準確率從 94.12% 提升至 96.67%。
- **性能巔峰：**IP-Xception 模型表現最為優異，達到了 98.21% 的最高驗證準確率。

Xception 之所以能超越 ResNet 與 Inception，關鍵在於其深度可分離卷積（Depthwise Separable Convolution）能更有效地分離空間特徵與通道資訊。而在加入 IP 預處理後，模型不再需要負擔學習「如何剔除無效背景」的運算成本，這在運算資源有限的場景下，能顯著減少訓練雜訊並提高對微小特徵（如掛繩纖

維) 的敏感度。

4. YOLOv8n 架構改良：遙測影像偵測的突破

遙測影像 (Remote Sensing) 偵測是資工領域公認的難題，主因在於物件微小且背景極度複雜，對模型提出了精準度與推理速度 (Inference speed) 的雙重考驗。

4.1 創新方法評估：YOLOv8n-TFBiCA

教授團隊提出的 YOLOv8n-TFBiCA 模型，在架構設計上有三點精確的微調：

1. **Bi-directional Feature Pyramid (Bi)**：增加特徵融合權重。
2. **Transformer 區塊**：具體做法是將 Backbone 中最後一個 C2f 模組替換為 Transformer 區塊。這彌補了 CNN 局部感受野的限制，增強了對遙測大場景的「全區域理解」能力。
3. **Coordinate Attention (CA)**：嵌入位置資訊，使模型能更明確地關注特徵圖中特定的空間座標。

4.2 數據對比與性能分析

- **mAP@0.5**：從 90.2% 提升至 94.5% (+4.3%)。
- **參數統計**：參數從 3.01M 降至 2.88M，模型反而更輕量化。
- **推理時間**：受到 Transformer 架構影響，時間從 3.0ms 增長至 4.0ms。

從研究角度看，這 1.0ms 的延遲增加是一個值得的「折衷」(Trade-off)。雖然 Transformer 減少了參數量 (Parameters)，但其自注意力機制的 FLOPs 計算複雜度較高，且目前硬體對非卷積架構的加速優化尚不如傳統 CNN 完善。然而，在 RTX 3060 平台上跑出 4.0ms 的表現，仍遠低於實時偵測的 33ms 標準，證明該改良模型在實時監測系統中具備高度部署可行性。

5. 總結、反思與未來研究導向

透過本次演講，我深刻體會到智慧系統的核心邏輯在於：「高質量的數據獲取」加上「具備硬體感知能力 (Hardware-aware) 的模型優化」。

5.1. 研究方法論總結

演講展示了一個典型的 雲端訓練、邊緣偵測 (Cloud-Edge split) 模型：利用強大的 RTX 3060 顯卡進行複雜模型的訓練，再將邏輯下放到如 ESP32 般的邊緣端執行。從智慧魚缸的數據傳輸到 YOLOv8 的架構微調，其核心皆在於如何針對具體場景 (如遙測、工業檢測) 優化訊號雜訊比。

5.2. 個人研究啟發

1. **影像預處理管線化**：教授提到的 IP 步驟對口罩檢測的提升（94% → 96%），讓我反思目前論文研究中是否過度依賴模型深度，而忽略了前端數據清洗與特徵工程的價值。
2. **Attention 機制的精準嵌入**：以前總認為 Transformer 是大型模型的專利，但演講中將其嵌入 YOLOv8n 的 Backbone 後端，證明了小模型也能透過局部架構改良換取全局視野。
3. **預防式分析的趨勢**：演講結尾提到的「AI 預測模型」將是下一波重點。不僅是「辨識」水質壞了沒，而是透過數據「預測」病菌何時增生，這是我未來在專題開發中希望嘗試的方向。

總結而言，陳教授的分享提醒了資工系研究生：理論研究若不結合具體的硬體限制與應用場景，則難以產生實際的社會價值。唯有「理論與實作並行」(Theory meets Practice)，才能開發出真正具備生命力的智慧系統。