

2026/03/31 書報討論演講報告：

如何打造台版 Edge Impulse TinyML 開發平台

演講者：歐尼克斯實境互動工作室創辦人 許哲豪博士

1. 導論：邊緣智能的戰略重估

當前全球 AI 研究的眼光大多聚焦於以 OpenAI 為首的大規模生成式 AI (GenAI)，追求近乎無限的雲端算力與超巨大模型。然而，身為一名專注於嵌入式系統的資工研究員，在參與虎尾科技大學電機資訊學院主辦、由 Edge AI Taiwan 許哲豪 (Jack Hsu) 主講的專題演講後，我深刻體認到另一個極端的技術戰略高地：**TinyML 與極小化邊緣運算**。

這場演講的核心衝突在於「雲端無限資源 (GPU/RAM)」與「邊緣極少資源 (MCU/SRAM)」的路線對抗。Jack 指出，邊緣智能 (Edge AI) 正經歷從單純的「感知 AI (感測聲音、影像)」跨越到具備自主決策能力的「代理 AI (Agentic AI)」以及與實體環境深度交互的「物理 AI (Physical AI)」的範式轉移。對於嵌入式系統研究而言，這意味著我們必須在極度受限的硬體規格下，實現從單一功能的模型推論轉向多模態、具備決策鏈的複雜系統。本次演講最重要的思辨在於：面對國際大廠的壟斷，台灣如何整合本土強大的晶片供應鏈，打造一個「台版 Edge Impulse 開發平台」，將開發流程民主化並守住數據主權。

2. 硬體架構的演進：突破邊緣運算的「四道牆」

在邊緣運算的實作路徑中，研究者最先撞上的便是硬體資源的物理極限，不需要面對傳統的算力牆 (Compute)、記憶體牆 (Memory) 能耗牆 (Power)，更必須納入通訊牆 (Communication Wall) 的考量，這四道牆決定了模型推論在端點設備上的可行性。

為了應對矩陣運算核心 ($Y=AX+B$) 帶來的計算負荷，硬體架構正從通用運算轉向專用加速。下表彙整了目前主流硬體在「彈性」與「效能」間的技術權衡：

加速晶片 類型	核心技術特性	彈性 / 通用性	效能 / 專用性
CPU	多核心、高時脈，適合處理一般邏輯判斷。	最高	最低
GPU	具備超多乘加運算單元 (MACs)，支援高速平行運算。	高	中
DSP	提供多乘加飽和運算 (Saturated Math)，適合訊號前處理。	中	中
NPU	專為神經網路資料流設計 (如 Arm Ethos 系列)，效能功耗比極佳。	中	高
FPGA	可編程邏輯，常用於專用 IC 前的電路驗證與時序敏感任務。	中	高
ASIC	針對特定 AI 任務硬化 (Hardwired) 的專用晶片。	最低	最高

從研究視角分析，目前的趨勢正從「純軟體優化」轉向「軟硬體協同設計 (Hardware-Software Co-design)」，必須在設計階段就考量量化格式對效能的影響，算力單位已從 MOPS 跨越至 TOPS，而支援的資料格式也從 FP32、INT8 進化到更高壓縮比的 FP4 或 INT4。這種向低位元 (Sub-8-bit) 量化的演進，是突破記憶體牆與能耗牆的核心研究課題。

3. 台灣 Edge AI 晶片生態系：台版平台的硬體基礎

台灣具備全球最完整的半導體生態，這是在地化 TinyML 平台發展的最強後盾。Jack 在演講中梳理了台灣晶片商如何將專用 NPU 整合進低成本 MCU，讓微型運算具備強大的感知能力：

- **奇景光電 (Himax) - HX6538 (WiseEye2)**：這是極具代表性的硬體配置，搭載了 2 顆 Arm Cortex-M55 核心(分別運行於 150MHz 與 400MHz)，並整合了 Arm Ethos-U55 MicroNPU。這種「大核帶小核」的配置能兼顧常駐感測 (Always-on) 與高效能推論。
- **新唐 (Nuvoton) - M55M1 系列**：與工研院 (ITRI) 深度合作，推動「雙腦協作」概念。這標誌著台灣廠商正從單純的晶片供應商，轉向提供結合「領域知識 (Domain Knowledge)」與「微型運算平台」的完整解決方案。
- **瑞昱 (Realtek) - RTL8735B (AmebaPRO2)**：鎖定影像連網應用，提供 0.4 TOPS 的 NPU 算力，展現了高集成度 SoC 在物聯網端的優勢。

台灣廠商透過整合 Arm Ethos 系列 NPU，實質上降低了中小企業進入 AI 應用的門檻。未來「台版平台」的價值不在於重造輪子，而在於如何將這些在地硬體的特性（如特定硬體指令集、SRAM 佈局）與開發工具鏈深度綁定。

4. 軟體工具鏈與開發流程：從編碼轉向數據工程

對於研究員而言，開發效率的瓶頸已從「如何寫模型」轉向「如何優化硬體部署」。以 Edge Impulse 為代表的端到端（End-to-End）平台，正重新定義嵌入式開發流程：

1. **資料工程**：利用 Roboflow 進行影像標註，解決資料獲取與整理的痛點。
2. **衡量設計（Impulse Design）**：整合 DSP 前處理與神經網路模型。
3. **效能校正與 EON Tuner**：這是該平台的核心價值。它能針對受限的記憶體足跡（Memory Footprint）自動進行超參數搜尋，解決了研究者在不同硬體上進行手動調參的噩夢。
4. **模型優化與轉換**：透過量化感知訓練（QAT）與編譯器優化（如 Vela 編譯器），將模型精準對應至特定 NPU。

這種工具鏈的民主化，讓研究者能從瑣碎的底層驅動編寫中解放，轉而專注於「模型架構創新」與「資料質量優化」。

5. 產業動態與未來展望：國際整合與台版需求

邊緣運算市場正經歷劇烈的商業整合。2025 年是關鍵的轉折點：Qualcomm 先後於 3 月與 10 月收購了 Edge Impulse 與 Arduino。這意味著未來硬體與軟體開發平台將呈現高度垂直整合。

在硬體進展上，我們必須精確區分產品線：

- **Arduino UNO Q (2025)**: 採用 Qualcomm Dragonwing QRB2210，為入門級 AI 應用。
- **Arduino Ventuno Q (2026)**: 搭載更高階核心，具備高達 40 TOPS 的 NPU 算力，這將使邊緣設備能運行更複雜的代理 AI 任務。

除了技術面的在地支援，更核心的因素在於「數據主權（Data Sovereignty）」與特定垂直市場（如台灣特有的智慧製造生產線）的客製化需求。建立本土生態系能確保敏感數據不外流至國外雲端平台，並能針對台灣半導體產業優勢進行深度優化。

6. 結論：研究生視角的自我反思與行動指南

這場演講徹底重塑了我對「模型優化」的定義。身為資工研究員，我們不能再沉溺於 PC 端的高 Accuracy，而必須具備「硬體感知（Hardware-aware）」的思維。

本次演講帶來的核心啟示如下：

- **定義的精確化：**廣義的 EdgeAI 指的是「不上網就能推論」；但狹義且更具挑戰性的則是「由電池供電的獨立裝置（Endpoint Device）」。
- **突破壁壘：**研究重心應放在如何克服「算力、記憶體、能耗、通訊」這四道牆。特別是在設計階段就必須考量量化（INT8/FP4）對模型精準度與 Cycle-accurate 效能的影響。
- **技術轉向：**隨著邊緣算力向 40 TOPS 邁進，研究方向應從單一感知的模型，轉向思考如何實踐「代理 AI」在受限資源下的任務鏈編排。

TinyML 不是要取代雲端，而是要賦予終端設備獨立的「靈魂」。在物理世界與數位智能深度交織的未來，具備軟硬體整合能力的工程師，才是掌握下一個 AI 時代門票的人。

5.1. 個人研究啟發

1. **影像預處理管線化**：教授提到的 IP 步驟對口罩檢測的提升（94% → 96%），讓我反思目前論文研究中是否過度依賴模型深度，而忽略了前端數據清洗與特徵工程的價值。
2. **Attention 機制的精準嵌入**：以前總認為 Transformer 是大型模型的專利，但演講中將其嵌入 YOLOv8n 的 Backbone 後端，證明了小模型也能透過局部架構改良換取全局視野。
3. **預防式分析的趨勢**：演講結尾提到的「AI 預測模型」將是下一波重點。不僅是「辨識」水質壞了沒，而是透過數據「預測」病菌何時增生，這是我未來在專題開發中希望嘗試的方向。

總結而言，陳教授的分享提醒了資工系研究生：理論研究若不結合具體的硬體限制與應用場景，則難以產生實際的社會價值。唯有「理論與實作並行」(Theory meets Practice)，才能開發出真正具備生命力的智慧系統。